



Do Texto à Decisão: um Índice de Tom de Avaliações e a Satisfação do Cliente

Exemplo de paper técnico no padrão Análise Macro (disciplina AI Applications)

Aluno(a) Exemplo — MBA AI Applications

27 de junho de 2026

Versão 1.0

Resumo. As avaliações textuais que clientes deixam após um atendimento carregam, em escolhas sutis de linguagem, informação sobre a satisfação que uma nota numérica isolada não captura. Este trabalho ilustra, com dados simulados para fins didáticos, a construção de um *Índice de Tom* dessas avaliações usando um modelo de linguagem de grande porte (LLM) com saída estruturada via Pydantic, e calibra esse índice contra a satisfação observada (NPS) por meio de regressão linear simples. O objetivo não é o resultado em si — os dados são sintéticos — mas demonstrar o **formato de entrega** esperado na disciplina: um *pipeline* reproduzível em que todo número exibido nasce de um *chunk* que roda. No exercício, o tom explica parcela relevante da variação de satisfação, com sensibilidade $\hat{\beta}$ positiva e estatisticamente significativa, evidenciando que medir tom agrega sinal sobre a nota bruta.

Palavras-chave: Processamento de Linguagem Natural; LLM; Saída Estruturada; Satisfação do Cliente; CRISP-DM.

1 Introdução

Empresas coletam, todos os dias, milhares de avaliações textuais. A nota numérica resume parte da experiência, mas o **tom do texto** — entusiasmo, frustração, ironia — guarda sinal adicional sobre a satisfação real e sobre o risco de *churn*. Transformar esse texto em um **número comparável** permite usá-lo em modelos de decisão.

Este paper é um **exemplo didático** da disciplina *AI Applications*: mostra, do começo ao fim, como entregar um relatório técnico reproduzível no padrão Análise Macro. Os dados são **simulados de propósito**, para que o documento renderize sem chaves de API; o que importa aqui é o **método e o formato**, não o resultado numérico.

2 Revisão da Literatura

A medição de tom em texto econômico-financeiro tem tradição em dicionários (Loughran e McDonald 2011), depois ampliada por métodos supervisionados e, mais recentemente, por LLMs com saída estruturada (Anthropic 2026). A contribuição metodológica deste exemplo é combinar **scoring por LLM** com **calibração estatística** simples e auditável.

3 Metodologia e Dados

Seguimos o fluxo **CRISP-DM**: (i) *entendimento do negócio* — prever satisfação a partir de avaliações; (ii) *dados* — avaliações textuais + NPS observado; (iii) *preparação* — limpeza e recorte; (iv) *modelagem* — score de tom por LLM (escala -3 a $+3$) via schema Pydantic; (v) *avaliação* — OLS do NPS sobre o score; (vi) *implantação* — este paper reproduzível.

A seção de Modelagem mostra o **schema de saída estruturada** que seria usado em produção; para manter o exemplo offline, a calibração roda sobre um conjunto **simulado** de scores.

4 Implementação

4.1 Configuração do ambiente

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt

rng = np.random.default_rng(42) # semente fixa → resultado reproduzível
```

O bloco abaixo **não é executado** (eval: false): é o molde de como pontuar o tom de cada avaliação com um LLM, forçando um **float** via schema. Em um projeto real, ele preencheria a coluna **score**.

Tabela 1

(a) Calibração do NPS sobre o Índice de Tom (OLS).

Parâmetro	Estimativa
$\hat{\beta}$ (score)	11.965
IC 95% de β	[10.280; 13.650]
R^2	0.626
p -valor	0.0000
n	120

Dados simulados para fins didáticos. Erros-padrão clássicos (OLS).

```
import os
import anthropic
from pydantic import BaseModel, Field

class TomAvaliacao(BaseModel):
    score: float = Field(description="Tom de -3 (muito negativo) a +3 (muito positivo)")

cliente = anthropic.Anthropic(api_key=os.environ["ANTHROPIC_API_KEY"])
ferramenta = {
    "name": "registrar_tom",
    "description": "Registra o tom da avaliação.",
    "input_schema": TomAvaliacao.model_json_schema(),
}
# resposta = cliente.messages.create(model="claude-haiku-4-5", temperature=0,
#     tools=[ferramenta], tool_choice={"type": "tool", "name": "registrar_tom"}, ...)
```

4.2 Dados (simulados) e calibração

```
n = 120
# Score de tom "verdadeiro" e NPS gerado com relação linear + ruído.
score = rng.uniform(-3, 3, size=n)
nps = 50 + 12.0 * score + rng.normal(0, 15, size=n)
df = pd.DataFrame({"score": score, "nps": nps})

X = sm.add_constant(df["score"])
modelo = sm.OLS(df["nps"], X).fit()

beta = modelo.params["score"]
ic = modelo.conf_int().loc["score"]
r2 = modelo.rsquared
pval = modelo.pvalues["score"]
```

5 Resultados

A Tabela Tabela 1a traz a calibração. Todos os valores são lidos do objeto `modelo` — nada digitado à mão.




Figura 1: Dispersão entre Índice de Tom e NPS, com a reta calibrada.

O coeficiente $\hat{\beta}$ positivo e significativo (Tabela Tabela 1a) mostra que avaliações de tom mais positivo associam-se a NPS maior — exatamente o que se esperaria de um índice bem calibrado. Em um projeto real, o passo seguinte seria validar **fora da amostra**.

6 Próximos Passos

- Substituir os dados simulados por avaliações reais e rodar o scoring por LLM.
- Validar em camadas (*holdout* e *walk-forward*), como no projeto *Sentimento COPOM*.
- Comparar provedores de LLM sob o mesmo *prompt* e schema.

7 Conclusão

O exemplo entregou um **paper reprodutível** no padrão Análise Macro: capa, resumo, fluxo CRISP-DM, tabela em *booktabs/threeparttable* e figura — todos gerados por código. É esse o formato esperado na entrega final da disciplina.

8 Referências

Anthropic. 2026. *Anthropic API Documentation*. <https://docs.anthropic.com>.

Loughran, Tim, e Bill McDonald. 2011. “When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks”. *The Journal of Finance* 66 (1): 35–65.